Transformación de Datos con dplyr : : **HOJA DE REFERENCIA**

dplyr funciona con conductos y require **datos ordenados**.
En datos ordenados:

Cada **variable** tiene su propia **columna**

&

Cada **observación** tiene su propia **fila**

conductos
(pipes)

x %>% f(y) se convierte en **f(x, y)**

Resumir Casos

Estos aplican **funciones de resumen** a columnas para crear un nuevo cuadro. Funciones de resumen toman vectores como entrada y devuelven un solo valor (ver reversa).

summary function

summarise(.data, …)
Calcula cuadro de resúmenes. También **summarise_**().
summarise(mtcars, avg = mean(mpg))

count(x, ..., wt = NULL, sort = FALSE)
Conteo del número de filas en cada grupo, definido por las variables en … También **tally**().
count(iris, Species)

VARIACIONES

summarise_all() - Aplica funs a cada columna
summarise_at() - Aplica funs a columnas específicas.
summarise_if() - Aplica funs a todas las columnas de un tipo

Agrupar Casos

Usa **group_by()** para crear una copia "agrupada" de un cuadro. Funciones dplyr manipularán cada "grupo" por separado para luego combinar los resultados.

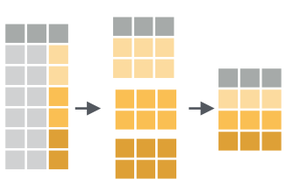

```
mtcars %>%
group_by(cyl) %>%
summarise(avg = mean(mpg))
```

group_by(.data, ..., add = FALSE**)**
Devuelve copia del cuadro agrupado por …
g_iris <- group_by(iris, Species)

ungroup(x, …**)**
Devuelve copia no-agrupada del cuadro
ungroup(g_iris)

Manipular Casos

EXTRAE CASOS

Funciones de Fila devuelven un sub-conjunto de filas como un nuevo cuadro. Usa la variante que termina en _ para código que funciona con evaluación no-estándar.

filter(.data, …**)** Extrae filas que cumplen criterios lógicos. También **filter_()**. *filter(iris, Sepal.Length > 7)*

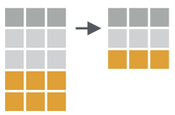

distinct(.data, ..., .keep_all = FALSE**)** Remueve filas duplicadas. También **distinct_()**.
distinct(iris, Species)

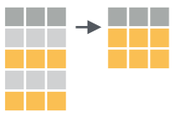

sample_frac(tbl, size = 1, replace = FALSE, weight = NULL, .env = parent.frame()**)** Selecciona una fracción de filas al azar.
sample_frac(iris, 0.5, replace = TRUE)

sample_n(tbl, size, replace = FALSE, weight = NULL, .env = parent.frame()**)** Selecciona n filas al azar. *sample_n(iris, 10, replace = TRUE)*

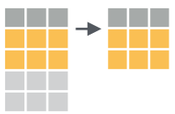

slice(.data, …**)** Selecciona filas por posición. También **slice_()**. *slice(iris, 10:15)*

top_n(x, n, wt**)** Selecciona y ordena las n entradas mas altas (por grupo si los datos están agrupados).
. top_n(iris, 5, Sepal.Width)

Operadores Lógicos y Booleanos para usar con filter()

<	<=	is.na()	%in%	|	xor()
>	>=	!is.na()	!	&	

Busca **?base::logic** y **?Comparison** para la documentación.

ORDENA CASOS

arrange(.data, …**)** Ordena filas por valores de una columna (bajo a alto), usa con **desc()** para ordenar de alto a bajo.
arrange(mtcars, mpg)
arrange(mtcars, desc(mpg))

AÑADE CASOS

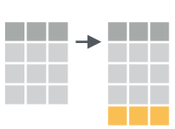

add_row(.data, ..., .before = NULL, .after = NULL**)**
Añade una o mas filas a un cuadro.
add_row(faithful, eruptions = 1, waiting = 1)

Manipular Variables

EXTRAER VARIABLES

Funciones de Columnas devuelven un conjunto de columnas como un nuevo cuadro. Usa la variante que termina en _ para código que funciona con evaluación no-estándar.

select(.data, …**)**
Selecciona columnas por nombre o funciones de ayuda. También **select_if()**
select(iris, Sepal.Length, Species)

Usa estos ayudantes con select (),
e.g. select(iris, starts_with("Sepal"))

contains(match**)**	**num_range(**prefix, range**)**	**:**, e.g. mpg:cyl
ends_with(match**)**	**one_of(**…**)**	**-**, e.g, -Species
matches(match**)**	**starts_with(**match**)**	

CREA NUEVAS VARIABLES

Estos aplican **funciones vectorizadas** a columnas. Funs vectorizadas toman vectores como entrada y devuelven vectores de la misma longitud como salida(ver reverso).

función vectorizada

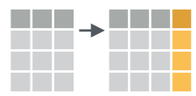

mutate(.data, …**)**
Calcula columna(s) nueva(s).
mutate(mtcars, gpm = 1/mpg)

transmute(.data, …**)**
Calcula columna(s) nueva(s), elimina otros.
transmute(mtcars, gpm = 1/mpg)

mutate_all(.tbl, .funs, …**)** Aplica funs a cada columna. Use con **funs()**.
mutate_all(faithful, funs(log(.), log2(.)))

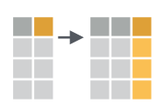

mutate_at(.tbl, .cols, .funs, …**)** Aplica funs a columnas específicas. Usa con **funs()**, **vars()** y la funciones de ayudar para select().
mutate_at(iris, vars(-Species), funs(log(.)))

mutate_if(.tbl, .predicate, .funs, …**)**
Aplica funs a todas las columnas de un tipo. Usa con **funs()**.
mutate_if(iris, is.numeric, funs(log(.)))

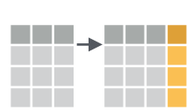

add_column(.data, ..., .before = NULL, .after = NULL**)** Añade nueva(s) columna(s).
add_column(mtcars, new = 1:32)

rename(.data, …**)** Renombra columnas.
rename(iris, Length = Sepal.Length)

Funciones de Vector

PARA USO CON MUTATE ()

mutate() y **transmute()** aplican funciones vectorizadas a columnas para crear nuevas columnas. Funciones vectorizadas toman vectores como entrada y devuelven vectores de la misma longitud.

función vectorizada →

CONTRARRESTAR

dplyr::**lag()** - Copia con valores atrasados por 1
dplyr::**lead()** - Copia con valores adelantados por 1

AGREGADOS AAcumulativoS

dplyr::**cumall()** - all() acumulativo
dplyr::**cumany()** - any() acumulativo
cummax() - max() acumulativo
dplyr::**cummean()** - mean() acumulativo
cummin() - min() acumulativo
cumprod() - prod() acumulativo
cumsum() - sum() acumulativo

RANKINGS

dplyr::**cume_dist()** - Proporción de todos los valores <=
dplyr::**dense_rank()** - clasificación con empates = min, sin brechas
dplyr::**min_rank()** - clasificación con empates = min
dplyr::**ntile()** - asigna a n intervalos (*bins*)
dplyr::**percent_rank()** - min_rank escalado a [0,1]
dplyr::**row_number()** - clasificación con empates = “first" (el primero)

MATEMATICAS

+, - , *, /, ^, %/%, %% - ops aritméticas
log(), log2(), log10() - logs
<, <=, >, >=, !=, == - comparaciones lógicas

MISCELÁNEAS

dplyr::**between()** - x >= izquierda & x <= derecha
dplyr::**case_when()** - casos-multiples if_else()
dplyr::**coalesce()** - primer elemento no-NA por elemento a lo largo de un conjunto de vectores
dplyr::**if_else()** - if() + else() por elemento
dplyr::**na_if()** - reemplaza valores específicos con NA
pmax() - max() por elemento
pmin() - min() por elemento
dplyr::**recode()** - switch() vectorizado
dplyr::**recode_factor()** - switch() vectorizado para factores

Funciones de Resumen

PARA USO CON SUMMARISE ()

summarise() aplica funciones de resumen a columnas para crear un nuevo cuadro. Funciones de resumen toman vectores como entrada y devuelven un solo valor.

función de resumen →

CONTEOS

dplyr::**n()** - número de valores / filas
dplyr::**n_distinct()** - # de únicos
sum(!is.na()) - # de no-NA’s

POSICIÓN

mean() - promedio, también **mean(!is.na())**
median() - mediana

LÓGICOS

mean() - proporción de TRUE’s
sum() - # de TRUE’s

POSICIÓN/ORDEN

dplyr::**first()** - primer valor
dplyr::**last**() - último valor
dplyr::**nth**() - valor en posición n del vector

RANGO

quantile() - centil n
min() - valor mínimo
max() - valor máximo

PROPAGACIÓN

IQR() - rango inter-centil
mad() - desviación absoluta media
sd() - desviación estándar
var() - varianza

Nombres Filas

Datos ordenados no usan nombres de filas, que implica un valor fuera de las columnas. Para trabajar con nombres de filas primero muevelos a una columna.

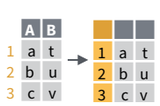

rownames_to_column()
Mueve nombres de filas a una col.
a <- rownames_to_column(iris, var = "C")

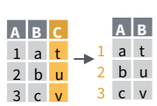

column_to_rownames()
Mueve columna a nombre de filas.
column_to_rownames(a, var = "C")

También **has_rownames()**, **remove_rownames()**

Combina Cuadros

COMBINA VARIABLES

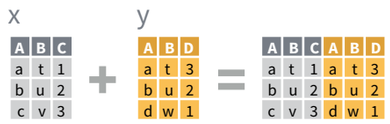

Usa **bind_cols()** para unir cuadros uno al lado del otro tal como son.

bind_cols(…) Devuelve cuadros posicionados lado a lado como un solo cuadro ASEGÚRATE QUE LAS FILAS COINCIDEN.

Usa una "**Unión Mutante**" para unir un cuadro a columnas de otro cuadro, buscando valores correspondientes en las filas. Cada unión retiene una combinación diferente de los valores de los cuadros.

left_join(x, y, by = NULL, copy=FALSE, suffix=c(“.x”,“.y”),…**)**
Une filas coincidentes de y a x.

right_join(x, y, by = NULL, copy = FALSE, suffix=c(“.x”,“.y”),…**)**
Une filas coincidentes de x a y.

inner_join(x, y, by = NULL, copy = FALSE, suffix=c(“.x”,“.y”),…**)**
Une datos. Mantener solo filas en ambos.

full_join(x, y, by = NULL, copy=FALSE, suffix=c(“.x”,“.y”),…**)**
Une datos. Mantener todos los valores, todas las filas.

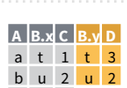

Usa **by = c("col1", "col2")** para especificar cuales columnas usar para determinar coincidencias.
left_join(x, y, by = "A")

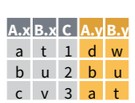

Usa un vector con nombres, **by = c("col1" = "col2")**, para determinar coincidencias en columnas con diferentes nombres en cada conjunto de datos.
left_join(x, y, by = c("C" = "D"))

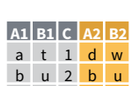

Usa **suffix** para especificar el sufijo para dar a nombres de columnas duplicadas.
left_join(x, y, by = c("C" = "D"), suffix = c("1", "2"))

COMBINA CASOS

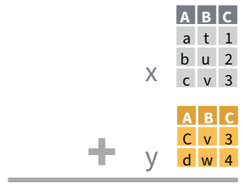

Usa **bind_rows()** para unir cuadros uno debajo del otro tal como son.

bind_rows(…, .id = NULL**)**
Devuelve cuadros uno encima del otro como un solo cuadro. Fija .id a un nombre de columna para añadir una columna con los nombres del cuadro de proveniencia originales (como en la figura)

intersect(x, y, …)
Filas que aparecen en ambos x y y.

setdiff(x, y, …)
Filas que aparecen en x pero no en y.

union(x, y, …)
Filas que aparecen en x o y (removiendo duplicados). union_all() retiene duplicados.

Usa **setequal()** para probar si dos conjuntos de datos contienen el número exactamente igual de filas (en cualquier orden).

EXTRAE FILAS

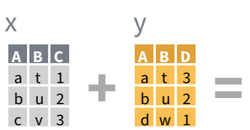

Usa una “**Unión de Filtro**" para filtrar un cuadro contra las filas de otro.

semi_join(x, y, by = NULL, …**)**
Devuelve filas de x que coinciden en y.
ÚTIL PARA VER QUE SE VA A UNIR.

anti_join(x, y, by = NULL, …**)**
Devuelve filas de x que no coinciden en y.
ÚTIL PARA VER QUE NO SE VA A UNIR.

RStudio